

Стратегия проекта AI-рекомендаций

Требования · контракт · риски · путь от PoC к эксплуатации

Статус и назначение

Учебный проект подготовлен к первичному обсуждению. Это не окончательное коммерческое предложение: сроки и пороги ниже являются допущениями до интервью, обследования данных, расчёта A/B-теста и согласования нефункциональных требований.

POC	MVP	ЭКСПЛУАТАЦИЯ
6 недель* техническая выполнимость	10–12 недель* ценность на пользователях	8–12 недель* масштаб и эксплуатация

Принцип доказательности

* Сроки — учебные допущения, а не сведения из задания. Метки пособия: ЗАДАНИЕ — дано OTUS; МЕТОДИКА — взято из источника; ДОПУЩЕНИЕ — предложено для планирования; РАСЧЁТ — получается на фактических данных.

1 · Вопросы для снятия неопределённости

01	Бизнес-цель Какой KPI главный: выручка на сессию, конверсия, средний чек, CTR, повторные покупки или маржинальность? Каковы baseline и минимально значимый эффект?
02	Поверхность и аудитория Где показываем рекомендации; кому; какой регион, бренд и доля каталога входят в scope?
03	Измерение эффекта Какие правила/модели уже работают, как рандомизируем трафик и сколько длится сезонный цикл?
04	Данные и право Какие user/item ID, события, остатки, цены, согласия и сроки хранения доступны и законны для профилирования?
05	NFR и интеграции Какие API, p95 latency, RPS, доступность, freshness, облако/on-prem, бюджет и fallback обязательны?
06	Ограничения Какие категории, бренды, возрастные товары, fairness/diversity и нежелательные сочетания запрещены?
07	Управление Кто владеет продуктом, данными, ИБ и Legal/DPO; кто утверждает GO/NO-GO и Change Request?

2 · Контрактная стратегия

Этап	Модель	Почему	Защита заказчика	Защита интегратора
PoC 6 недель	T&M; with a cap	Неизвестны качество данных, достижимый uplift и интеграционная сложность.	Лимит бюджета; timebox; weekly burn; право STOP.	Гипотеза меняется без скрытого бесплатного scope.
MVP + основная разработка	Гибрид	После PoC часть результата стабильна, но эксперименты остаются.	FP для stage gates; capped change budget; прозрачная приёмка.	Изменения данных/правил/API проходят CR и оплачиваются.

Условия коммерческого контроля

Baseline score, допущения и зависимости входят в приложение к договору. Еженедельно фиксируются burn, результат эксперимента и forecast. GO/PIVOT/STOP принимается по DoD. Резерв изменений 15-20% — рабочее допущение, уточняемое после PoC.

Черновик Change Request

CR ID / инициатор	уникальный номер, дата, владелец
Причина	новое требование, данные, регуляторное/технологическое ограничение
Изменение	score, KPI, данные, модель, API, NFR
Влияние	стоимость, срок, архитектура, ИБ, эксплуатация, риски
Варианты	отклонить / backlog / заменить score / change budget
Решение	новая baseline-версия и критерии приёмки
Согласование	заказчик, интегратор, Product; при необходимости ИБ/Legal/DPO

3 · Матрица AI-рисков

Р и I: 1 — очень низко, 5 — очень высоко. S=P×I: 1-5 низкий, 6-10 средний, 11-15 высокий, 16-25 критический. Остаток — оценка после мер.

ID	Риск	P	I	S	Владелец	Меры	Триггер	Ост.
R1	Качество/смещение данных	4	5	20	Data Owner	data contract; profiling; quarantine	ID<90% / SKU attrs<95%	10
R2	Offline ≠ business uplift	4	4	16	Product	baseline; A/B; power; guardrails	uplift<MDE	8
R3	Drift и сезонность	4	4	16	ML Lead	time split; monitor; retrain	PSI>0,2 / KPI −5%	8
R4	Остатки/цены устарели	3	5	15	Integration	freshness SLO; pre-filter	invalid>0,5%	5
R5	Cold start	4	3	12	ML Lead	content/popularity fallback	cold-start>20%	6
R6	Feedback loop / bias	3	4	12	Product+ML	diversity; exploration; audit	segment gap	6
R7	Consent / profiling	3	5	15	Legal/DPO	DPIA; minimization; deletion	нет lawful basis	5
R8	Latency / scale	3	4	12	Architect/SRE	load test; cache; timeout	p95>150 ms	6
R9	Forbidden suggestions	2	5	10	Safety	policy engine; tests; kill switch	policy breach	5

Методическая оговорка

Матрица нужна для первичной сортировки. Шкала 1-5, границы зон и сами баллы — допущения этой работы, а не норматив. Для бюджета и срока риск связывается с целевым показателем и диапазоном последствий; точность результата не должна превышать качество исходных данных.

4 · Дорожная карта: PoC → MVP → эксплуатация

Все сроки и числовые пороги на этой странице — учебные допущения. Способ их получения приведён в паспорте чисел.

01	PoC · 6 недель Проверить техническую выполнимость Результат: Data audit; baseline; 2-3 модели; offline evaluation; demo DoD: ID coverage ≥90%; SKU attrs ≥95%; legal/ИБ gate; NDCG@10 +10% к baseline; invalid <0,5%; GO/PIVOT/STOP
02	MVP · 10-12 недель Проверить ценность на пользователях Результат: 1 surface; API; pipeline; A/B 5-10%; monitoring; fallback DoD: A/B: рабочий порог CTR +3%; guardrails не хуже 1%; p95 ≤150 ms; ≥99,5%; rollback испытан
03	Production · 8-12 недель Масштабировать и управлять Результат: HA; retrain/deploy; drift+cost monitoring; runbooks; on-call DoD: 1,5× peak; p95 ≤100 ms/NFR; ≥99,9%; RTO/RPO; canary+rollback; 30 стабильных дней; TCO

Решения между этапами

Gate	Решение	Обязательные участники
PoC → MVP	GO / PIVOT / STOP по данным, offline quality, рискам и экономике эксперимента	Product, Architect, Data, ИБ, Legal/DPO, Finance
MVP → Prod	Масштабировать только при подтверждённом online uplift и выполненных NFR/guardrails	Заказчик, Product, Architect, SRE, ИБ, Legal/DPO

5 · Паспорт чисел

Число без происхождения создаёт ложную точность. Таблица отделяет данные задания от учебных допущений и показывает, чем их заменить на реальном проекте.

Число	Статус	Происхождение и уточнение
6 недель PoC	Допущение	1+1+2+1+1 недель: доступ; выборка и baseline; модели; проверка; демонстрация. Пересчитать после подтверждения команды и доступа.
10-12 недель MVP	Допущение	2-3 недели данные + 3-4 API/интеграция + 2-3 A/B-тест + 2 мониторинг и приёмка; часть работ параллельна.
8-12 недель эксплуатации	Допущение	Зависит от HA, инфраструктуры, согласований, нагрузочных испытаний и готовности эксплуатации.
90% / 95% покрытия	Допущение приёмки	Рассчитать профилированием: корректные записи / все целевые записи. Порог утверждает владелец данных.
NDCG@10 +10%	Допущение PoC	Сравнить с зафиксированным базовым алгоритмом на временной тестовой выборке.
CTR +3%	Пример MDE	Не включать в договор без расчёта: baseline CTR, трафик, уровень значимости и мощность теста.
150 / 100 мс	Допущение NFR	Разложить бюджет задержки между сетью, API, кандидатами, ранжированием и фильтром; проверить нагрузочным тестом.
99,5% / 99,9%	Допущение SLO	Выбрать по стоимости простоя. Бюджет недоступности = (1-SLO) × длительность периода.
Запас 1,5x	Допущение мощности	Уточнить по пику, росту, ошибке прогноза и времени масштабирования.
Баллы рисков	Экспертная гипотеза	Владельцы утверждают P и I; S=P×I; после мер оценка выполняется повторно.

Как получить фактические значения

Аналитика клиента → профилирование данных → расчёт мощности A/B-теста → нагрузочная модель → стоимость простоя и SLO → воркшоп владельцев рисков. Только после этого допущения становятся договорными критериями.

6 · Источники и границы применимости

GANTBPM — «Матрица рисков». Используются оси вероятность/влияние, размещение рисков по ячейкам и цветовая приоритизация. Источник:

<https://gantbpm.ru/matritsa-riskov-primer-zapolneniya-i-skachat-obrazets-v-eksel/>

АНО ДПО ИСАР / Risk Academy — количественный реестр. Модель содержит листы «Описание», «Риск_Калькулятор» и «Графики», автоматически пересчитывает результаты. Учтено предупреждение: риски следует связывать с влиянием на цели и показатели. Источник:

<https://risk-academy.ru/download/quant-risk-register/>

Материалы OTUS, урок 3. Исходное задание, Risk_Matrix_Example.xlsx и ISAR_Sample_risk_calculator_Final-252831-806a4a.xlsx находятся в папке урока.

Когда документ можно утверждать

После протокола интервью, отчёта о качестве данных, расчёта A/B-теста, нагрузочной модели, ТСО и согласования оценок рисков их владельцами. До этого документ остаётся учебным проектом для первичного обсуждения.

УЧЕБНЫЙ ПРОЕКТ · ПОДГОТОВЛЕН К ПЕРВИЧНОМУ ОБСУЖДЕНИЮ